Ayudantía 1

Manipulación de objetos en R

Santiago Ortúzar

saortuza@uc.cl

Estadística Descriptiva en R

Prof. Alejandro González

Universidad Alberto Hurtado - FEN

Viernes 1 de abril de 2022

Presentación

- Contacto: saortuza@uc.cl (mail UAH pendiente).
- Confianza:
 - Por favor, escribir SIEMPRE en caso de dudas.
 - Exigir feedback y apoyo.
- Ayudantías no son obligatorias ni tienen nota asociada.
 - Las/los invito a participar y tratar de ajustarse a la metodología que seguiremos en las ayudantías.

Calendario

- Tutorial instalación R y RStudio: Viernes 1 de abril (cápsula).
- Ayudantía 1: Viernes 1 de abril (cápsula).

Calendario todavía sujeto a confirmación por fechas de evaluaciones.

Plan para las ayudantías

- Primeras ayudantías: lo básico.
 - ¿Qué es R?
 - Instalar el software (R y RStudio).
 - Aprender a usar el software.

Metodología

- 5 cápsulas y 4 clases sincrónicas.
- Todas las ayudantías irán acompañadas de una presentación y una hoja de sintaxis en R.
- No desgastarse tomando apuntes, toda la información estará en las presentaciones.

Plan para esta sesión

- Manipulación de objetos en R:
 - Vectores.
 - Matrices.
 - Data frames.
 - Obtener información sobre variables en un data frame.

Usando RStudio

Observaciones

- El símbolo > en la consola indica que R no está corriendo ningún análisis actualmente y que podemos escribir e ingresar código.
- En principio, R lee líneas de código separadas por puntos aparte como funciones diferentes.
- Podemos correr funciones seleccionando el pedazo de texto (código) que nos interesa y apretando Control + Enter (para Windows) y Comando + Enter (MacOS).
- R permite agregar texto a nuestra hoja de sintaxis sin interpretarlo como código, siempre que esté escrito después de #.

Observaciones

```
55 + 45 # "55+45" es código de R, pero esto no

## [1] 100

# Esta función es útil para comentar nuestro código

# Ayuda a quien lo lea a entenderlo mejor

# (muchas veces nosotros mismos)
```

- Recordemos que R es un lenguaje de programación orientada a objetos.
- Un objeto en R es cualquier cosa a la que podamos asignar información numérica o alfabética.
- Para asignar información a un objeto, usaremos un símbolo de flecha hacia la izquierda: <-.</p>

```
objeto1 <- 1
objeto2 <- 1 + 1
objeto3 <- 2 - 1
```

- Estas son funciones para *crear* objetos, pero por sí mismos no nos "muestran" el objeto creado.
- Para "llamar" al objeto creado debemos escribir el nombre del objeto respectivo en la consola.

```
objeto1
```

```
## [1] 1
```

■ El objeto que aquí llamamos objeto1 contiene el valor numérico 1.

```
objeto2
```

```
## [1] 2
```

• objeto2 contiene la suma de 1+1, por lo tanto al "llamarlo" nos entrega el valor numérico 2.

```
objeto3
```

```
## [1] 1
```

- objeto3 contiene la resta de 2 1, por lo que nos reporta un valor número 1.
- Así, si bien objeto1 y objeto3 nos entregan la misma información (el valor 1), se generan a partir de funciones diferentes.

- Noten como cada objeto fue generado por código escrito en la sintaxis, que R reporta en la consola y se almacena en el environment.
- Los objetos pueden contener información no sólo numérica sino alfabética.
- Para almacenar texto en un objeto, debemos usar comillas: .

[1] "abcd"

```
objeto4 <- "texto"
objeto4
## [1] "texto"
objeto5 <- "abcd"
objeto5
```

Tipos de objetos en R

Ahora bien, en R hay muchos tipos de objetos, y por ahora nos interesan principalmente 2: los vectores y las bases de datos (data frames), aunque mencionaremos otros.

- Un vector es un tipo de objeto unidimensional que contiene información alfabética o numérica.
- Cuando hablamos de vectores, hablamos de objetos que ya no contienen sólo un valor sino varios valores.

[1] "a" "b" "c" "d" "e"

```
vector1 <- c(1, 2, 3, 4, 5)
vector1
## [1] 1 2 3 4 5
vector2 <- c("a", "b", "c", "d", "e")
vector2</pre>
```

Como vemos, vector1 contiene 5 valores numéricos, mientras que vector2 contiene 5 valores alfabéticos.

- El comando c(), llamado concatenate ("concatenar"), será fundamental para poder asignar múltiples valores (esto es, más de un ítem de información) a un mismo objeto.
- Al ir creando objetos de este tipo, R nos permite avanzar de a poco hacia operaciones más complejas.
- Por ejemplo, creemos otro vector llamado vector3 y sumémoslo a vector1.

[1] 7 9 11 13 15

```
vector3 <- c(6, 7, 8, 9, 10)
vector3
## [1] 6 7 8 9 10
vector1 + vector3</pre>
```

- Al sumar vector1 + vector3, obtenemos una nueva información en la consola: los valores 7 9 11 13 15.
- De hecho, podríamos repetir esta operación pero almacenarla en un nuevo vector: vector4.

[1] 7 9 11 13 15

```
vector1 + vector3

## [1] 7 9 11 13 15

vector4 <- vector1 + vector3

vector4</pre>
```

Sin embargo, no podríamos hacer algo similar con vector2, ya que éste contiene valores alfabéticos y no numéricos.

Si ingresan el código

vector1 + vector2

R entregará el siguiente mensaje:

Error in vector1 + vector2 : non-numeric argument to binary operator

- La razón por la que esto ocurre es que vector1 y vector2 pertenecen a "clases" diferentes.
- Con el comando class() podemos ver a qué clase corresponde cada uno.

```
class(vector1)

## [1] "numeric"

class(vector2)

## [1] "character"
```

- R indica que vector1 es de clase numérica, mientras que vector2 es un carácter. También hay una tercera clase de vector, "factor", que veremos más adelante y es muy útil.
 - Dato importante: si ingresamos números a un vector, pero los números van con comillas, R los entenderá como carácter, no como un valor numérico.

```
vector5 <- c("1", "2", "3", "4", "5")</pre>
vector5
## [1] "1" "2" "3" "4" "5"
class(vector5)
## [1] "character"
str(vector5)
## chr [1:5] "1" "2" "3" "4" "5"
```

■ La función str (structure) también reporta la clase del objeto, además de un resumen de su información.

```
str(vector5)
```

```
## chr [1:5] "1" "2" "3" "4" "5"
```

- En la práctica la gran mayoría de los análisis estadísticos que realizaremos usan vectores numéricos y factores.
- Las funciones de manipulación de texto y caracteres pueden ser muy útiles cuando tenemos que limpiar y depurar bases de datos.

Ejercicio

- Cree un vector que contenga los valores 5, 8, 3, 2 y 10, en ese orden. Llame al vector ejercicio.
- Realice las siguientes operaciones con el vector:
 - Sume 9 a ejercicio.
 - Multiplique ejercicio por 2.
 - Multiplique ejercicio por 5/7.
 - Eleve ejercicio al cuadrado.

Ejercicio

[1] 25 64 9 4 100

```
ejercicio \leftarrow c(5, 8, 3, 2, 10)
ejercicio + 9
## [1] 14 17 12 11 19
ejercicio * 2
## [1] 10 16 6 4 20
5 / 7 * ejercicio
## [1] 3.571429 5.714286 2.142857 1.428571 7.142857
ejercicio * ejercicio # o también:
## [1] 25 64 9 4 100
ejercicio^2
```

30 / 66

 Una matriz es un tipo de objeto bidimensional que, al igual que un vector, puede tomar valores alfabéticos o numéricos.

```
matriz1 <- matrix(1:25, nrow = 5, ncol = 5)
matriz1</pre>
```

```
## [,1] [,2] [,3] [,4] [,5]

## [1,] 1 6 11 16 21

## [2,] 2 7 12 17 22

## [3,] 3 8 13 18 23

## [4,] 4 9 14 19 24

## [5,] 5 10 15 20 25
```

■ El comando le dice a R que cree una matriz cuyos valores vayan del 1 al 25, con 5 filas y 5 columnas.

Podemos realizar todas las operaciones del álgebra de matrices:

```
matriz1 + matriz1
```

```
[,1] [,2] [,3] [,4] [,5]
##
## [1,]
        2
            12 22
                    32
                        42
  [2,]
        4 14 24 34 44
##
  [3,]
      6 16 26 36 46
##
## [4,]
      8 18 28 38 48
## [5.]
        10
            20
                30
                    40
                        50
```

- Nosotros no usaremos mucho las matrices propiamente tales, aunque a veces se pueden usar de forma auxiliar para asistir a otras funciones.
- Sí nos interesa poner atención a la notación de R: cuando vemos números separados por comas entre corchetes [,] estamos hablando de filas y columnas (en ese orden).
- Así, por ejemplo, podemos ver información sólo para filas y columnas de nuestro interés:

■ Cuarta fila y quinta columna de la matriz 1:

```
matriz1[4, 5]
## [1] 24
matriz1
      [,1] [,2] [,3] [,4] [,5]
##
## [1,]
        1 6 11 16
                      21
      2 7 12 17 22
  [2,]
##
  [3,]
      3 8 13 18 23
##
## [4,] 4 9 14 19 24
## [5,]
        5
            10 15
                   20
                       25
```

Tipos de objetos en R: bases de datos (data frames)

- Las bases de datos consisten en conjuntos de vectores portadores de valores numéricos o alfabéticos.
- Veamos una muestra de 373 casos elegidos al azar de la III Encuesta Nacional de Participación y Consumo Cultural (2009).

Tipos de objetos en R: bases de datos (data frames)

- La base de datos contiene las siguientes variables:
 - folio (identificador).
 - SEL_Sexo (quizá versiones más actualizadas preguntan por género).
 - SEL_Edad (edad como valor numérico).
 - SEL_NEduc (nivel educativo: grado más alto alcanzado).
 - libros_dummy: m6_64: Con excepción de textos escolares y considerando libros usados o nuevos, ¿ha leído usted algún libro en los últimos 12 meses? (variable dicotómica)
 - libros_numero: m6_66: En los últimos 12 meses, ¿cuántos libros ha leído? (variable numérica)
 - libros_frecuencia: m6_67: Sin considerar textos escolares, ¿con qué frecuencia acostumbra leer libros? (variable categórica con 4 categorías)

- Vamos a seleccionar el directorio donde trabajar:
 - ¿Cómo encontrar rápido el directorio?

getwd()

- ## [1] "C:/Github/uah_ayudantia_estadistica_2022/ayudantias_estadistica_descriptiva/ayudantia01"
 - Fijar directorio:

setwd("C:/GitHub/uah_ayudantia_estadistica_2022/ayudantias_estadistica_descriptiva/ayudantia01")

load("cc1.RData")

■ Decirle a R dónde buscar el dataframe en mi computador.

Comandos que servirán para examinar bases de datos: head(), tail(), str(), dim().

```
head(cc1a)
##
       folio SEL Sexo SEL Edad SEL NEduc libros dummy libros numero
## 2335 8577
               Hombre
                           27 Secundaria
## 1853 4924
               Hombre
                         47 Secundaria
              Mujer 44 Secundaria
Mujer 34 Secundaria
## 3311 8839 Mujer
                                                  Sí
## 1770 8709
                                                  Nο
                        24 Superior
## 3521 2962 Hombre
                                                  Sí
## 5686 2362 Mujer
                          70 Primaria
                                                  Sí
##
                     libros frecuencia
## 2335 Menos de una vez al año
## 1853
               Menos de una vez al año
## 3311 1 día por semana - 1 día al mes
## 1770
               Menos de una vez al año
## 3521 1 día por semana - 1 día al mes
## 5686
               Menos de una vez al mes
```

```
tail(cc1a)
       folio SEL_Sexo SEL_Edad SEL_NEduc libros_dummy libros_numero
## 7631 4310
               Hombre
                           37 Secundaria
## 4977 7062
                              Primaria
              Mujer
                                                  No
                      61
## 1285
        7734
              Muier
                                Superior
                                                  Sí
                      55 Secundaria
## 6407 2756 Hombre
                                                 No
## 5262
        2994
              Mujer
                                Primaria
                                                  Sí
## 4333 8578
               Hombre
                                Superior
                                                  Nο
##
                    libros frecuencia
## 7631 1 día por semana - 1 día al mes
## 4977
               Menos de una vez al año
## 1285
        Todos o casi todos los días
## 6407
               Menos de una vez al año
## 5262 1 día por semana - 1 día al mes
## 4333
               Menos de una vez al año
```

str(cc1a)

```
## 'data.frame': 373 obs. of 7 variables:
   $ folio
                      : int 8577 4924 8839 8709 2962 2362 6247 3396 4163 6779
##
   $ SEL Sexo
                      : chr "Hombre" "Hombre" "Mujer" "Mujer" ...
##
##
   $ SEL Edad
                      : int 27 47 44 34 24 70 25 49 49 68 ...
   $ SEL_NEduc : Factor w/ 3 levels "Primaria", "Secundaria", ...: 2 2 2 2
##
##
   $ libros dummy : chr "No" "No" "Sí" "No" ...
##
   $ libros numero : int 0 0 4 0 5 1 0 2 2 2 ...
   $ libros_frecuencia: Factor w/ 4 levels "Todos o casi todos los días",...: 4
##
   - attr(*, "na.action") = 'omit' Named int [1:27] 9 25 29 44 74 76 119 132 14
##
    ..- attr(*, "names")= chr [1:27] "7054" "355" "2268" "2993" ...
##
```

[1] 373 7

```
dim(cc1a)
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Conteo de frecuencias de sexo y lectura de libros en el último año:

```
##
## Hombre Mujer
## 172 201
table(cc1a$libros_dummy)
```

```
## No Si
## 198 175
```

##

No

0.5308311 0.4691689

Tipos de objetos en R: bases de datos (data frames)

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:

Sí

Proporciones de cada categoría de sexo y lectura en los últimos 12 meses:

```
##
## Hombre Mujer
## 0.461126 0.538874

prop.table(table(cc1a$libros_dummy))
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Frecuencias de qué tan seguido leen las personas encuestadas:

```
##
## Todos o casi todos los días 1 día por semana - 1 día al mes
## 58 75
## Menos de una vez al mes Menos de una vez al año
## 198
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Proporciones de qué tan seguido leen las personas encuestadas:

```
##
## Todos o casi todos los días 1 día por semana - 1 día al mes
## 0.1554960 0.2010724
## Menos de una vez al mes Menos de una vez al año
## 0.1126005 0.5308311
```

- Proporciones de qué tan seguido leen las personas encuestadas:
- Para mejor presentación de las proporciones:

- Proporciones de qué tan seguido leen las personas encuestadas:
- Para mejor presentación de las proporciones:

```
round(100 * prop.table(table(cc1a$libros_frecuencia)), digits = 1)

##

## Todos o casi todos los días 1 día por semana - 1 día al mes
## 15.5 20.1

## Menos de una vez al mes Menos de una vez al año
## 11.3 53.1
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos:

[1] 0

¿Cuáles son la media y la mediana de libros leídos el último año?

```
mean(cc1a$libros_numero)

## [1] 1.865952

median(cc1a$libros_numero)
```

- Al igual que con las matrices, podemos utilizar los corchetes para señalar filas y columnas de nuestro interés.
- Por ejemplo, veamos qué valor tiene en la fila 100 la pregunta sobre frecuencia de lectura:

```
## [1] Todos o casi todos los días
## 4 Levels: Todos o casi todos los días ... Menos de una vez al año
# o lo mismo escrito de otra forma:
cc1a[100, 7]

## [1] Todos o casi todos los días
## 4 Levels: Todos o casi todos los días ... Menos de una vez al año
# porque libros_frecuencia es la séptima variable (columna)
# de nuestro data frame
```

O los valores de las tres variables sobre lectura en las filas 150 y 251:

```
cc1a[150, c("libros_dummy", "libros_numero", "libros_frecuencia")]
       libros_dummy libros_numero libros_frecuencia
## 8049
                   O Menos de una vez al año
cc1a[251, c("libros_dummy", "libros_numero", "libros_frecuencia")]
      libros_dummy libros_numero libros_frecuencia
                     2 Todos o casi todos los días
## 536
# o lo mismo escrito de otra forma:
cc1a[251, 5:7]
      libros_dummy libros_numero libros_frecuencia
               Sí 2 Todos o casi todos los días
## 536
# porque las variables son la número 5, 6 v 7
# de nuestro data frame
```

- Veamos ahora algunos descriptivos bivariados (variable numérica según variable categórica):
 - Cómo se distribuyen las *medias* de una variable numérica según las diferentes *categorías* de nivel educativo y sexo.

```
tapply(cc1a$libros_numero, cc1a$SEL_NEduc, mean)

## Primaria Secundaria Superior
## 1.021505 1.804878 3.080000

# media de libros leídos por año según nivel educativo

tapply(cc1a$libros_numero, cc1a$SEL_Sexo, mean)

## Hombre Mujer
```

1.110465 2.512438

Menos de una vez al mes

Tipos de objetos en R: bases de datos (data frames)

 Veamos ahora algunos descriptivos bivariados (asociación entre variables categóricas, que se registra en una tabla de contingencia):

```
table(cc1a$libros_frecuencia, cc1a$SEL_NEduc)
##
##
                                      Primaria Secundaria Superior
##
    Todos o casi todos los días
                                                       26
                                                                18
##
     1 día por semana - 1 día al mes
                                            13
                                                                11
    Menos de una vez al mes
                                                      21
                                                                17
    Menos de una vez al año
                                            62
                                                      107
                                                                29
# frecuencia de lectura según nivel educativo
# quardemos esto como objeto para mayor simplicidad:
lectura NEduc <- table(cc1a$libros frecuencia, cc1a$SEL NEduc)
# lo mismo de otra manera:
xtabs(~ libros frecuencia + SEL NEduc, data = cc1a)
##
                                    SEL_NEduc
                                     Primaria Secundaria Superior
## libros_frecuencia
    Todos o casi todos los días
                                            14
                                                       26
                                                                18
    1 día por semana - 1 día al mes
                                            13
                                                                11
```

21

17

- Veamos ahora algunos descriptivos bivariados (asociación entre variables categóricas):
 - Se entiende mejor con proporciones:

```
round(100 * prop.table(lectura_NEduc), 2)
```

```
##
##
                                   Primaria Secundaria Superior
##
    Todos o casi todos los días
                                      3.75
                                                 6.97
                                                         4.83
    1 día por semana - 1 día al mes
                                      3.49
                                                13.67
                                                         2.95
##
##
    Menos de una vez al mes
                                     1.07
                                                 5.63 4.56
##
    Menos de una vez al año
                                     16.62
                                                28.69
                                                         7.77
```

- Veamos ahora algunos descriptivos bivariados (asociación entre variables categóricas):
 - Se entiende mejor con proporciones (porcentaje de columna):

```
round(100 * prop.table(lectura_NEduc, margin = 2), 2)
```

```
##
##
                                  Primaria Secundaria Superior
    Todos o casi todos los días
                                     15.05
                                               12.68
                                                       24.00
##
##
    1 día por semana - 1 día al mes
                                   13.98
                                               24.88
                                                       14.67
    Menos de una vez al mes
##
                                    4.30
                                               10.24
                                                       22.67
##
    Menos de una vez al año
                                     66.67
                                               52.20
                                                       38.67
```

```
# el porcentaje de columna se especifica con marqin=2
```

```
##
##
                                      Primaria Secundaria Superior
                                         15.05
                                                    12.68
                                                              24.00
##
     Todos o casi todos los días
##
     1 día por semana - 1 día al mes
                                         13.98
                                                    24.88
                                                              14.67
     Menos de una vez al mes
                                         4 30
                                                    10.24
                                                              22.67
##
##
     Menos de una vez al año
                                         66.67
                                                    52.20
                                                              38.67
```

- i. ¿Cómo interpretar el porcentaje de columna? De arriba hacia abajo, todas las columnas suman 100 % (no así las filas de izquierda a derecha).
- Nos indican cómo varía la frecuencia de lectura según nivel educativo.
- Así, entre quienes están/alcanzaron la primaria, alrededor del 67 % declara que lee menos de un libro al año, mientras que el 15 % lee todos o casi todos los días.
- Entre quienes están/alcanzaron la educación superior, alrededor del 39 % no lee casi nunca, mientras que el 24 % lee todos o casi todos los días.

Ahora con *porcentaje de fila*:

```
round(100 * prop.table(lectura_NEduc, margin = 1), 2)
##
##
                                     Primaria Secundaria Superior
##
     Todos o casi todos los días
                                         24.14
                                                    44 83
                                                             31.03
     1 día por semana - 1 día al mes
                                        17.33
                                                    68.00
                                                             14.67
##
    Menos de una vez al mes
                                         9.52
                                                    50.00
                                                             40.48
##
##
     Menos de una vez al año
                                        31.31
                                                    54.04
                                                            14.65
```

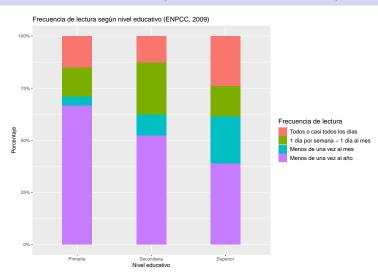
- # el porcentaje de columna se especifica con margin=1
 - ¿Cómo interpretar el porcentaje de fila? De izquierda a derecha, todas las filas suman 100% (no así las columnas de arriba hacia abajo).
 - Nos indica cómo varía el nivel educativo en cada tramo/grupo/categoría de frecuencia de lectura.
 - Así, entre quienes leen todos/casi todos los días, alrededor del 24 % alcanzó la educación primaria, mientras que el 31 % alcanzó la educación superior.
 - Entre quienes leen menos de un libro al año, el 31 % alcanzó la primaria, mientras que el 15 % alcanzó la educación superior.

Propuesta de ejercicio

Propuesta de ejercicio (totalmente voluntario)

- Utilizando la base de datos cc1a (archivo cc1.Rdata) que analizamos esta clase, y el código visto en clases y en ayudantía, haga un análisis de la lectura en Chile según nuestros datos.
- Puede incluir tablas de descriptivos univariados o bivariados, además de gráficos.

Propuesta de ejercicio (totalmente voluntario)



Propuesta de ejercicio (totalmente voluntario)

- Más allá del código, ¿qué información o aprendizaje nos dejan los datos? ¿Hay alguna hipótesis que le parezca pertinente investigar? Sea creativo/a, estamos aprendiendo y equivocarnos da lo mismo.
- Este ejercicio se trata en parte de usar el código, pero también de formular una narración que resuma lo que aprendimos de los datos.
- Deberíamos aspirar a analizar datos para poder evaluar argumentos y teorías.

Bibliografía

Referencias sugeridas

En castellano:

- Hernández, F., & Usuga, O. (2021a). Introducción. En Manual de R. https://fhernanb.github.io/Manual-de-R/ (disponible gratuitamente online).
- Hernández, F., & Usuga, O. (2021b). Tipos de objetos. En Manual de R. https://fhernanb.github.io/Manual-de-R/objetos.html (disponible gratuitamente online).

Referencias sugeridas

En inglés:

■ Paradis, E. (2013). *R for Beginners*. 1–52.

Referencias complementarias (consulta)

- Beaujean, A. A. (2014). Introduction to R. En Latent Variable Modeling Using R (pp. 1–33). Routledge.
- Gorgas, J., & Cardiel, N. (s.f.). Tema 1: Introducción al paquete de software R. https://www.ucm.es/data/cont/docs/339-2016-09-29-Introduccion%20a%20R_v1617.pdf (infografías).
- Zuur, A. F., Ieno, E. N., & Meesters, E. H. W. G. (2009). Ch.
 2: Getting Data into R. En A Beginner's Guide to R
 (pp. 29–56). Springer.

Sobre la lectura

- La lectura es de carácter voluntario y no se evaluará.
- Se recomienda leer 1 de las lecturas sugeridas y revisar las complementarias como material de consulta.