Ayudantía 1

Manipulación de objetos en R

Santiago Ortúzar

saortuza@uc.cl

Estadística Descriptiva en R

Prof. Alejandro González

Universidad Alberto Hurtado - FEN

Viernes 1 de abril de 2022

Presentación

- Contacto: saortuza@uc.cl (mail UAH pendiente).
- Confianza:
 - Por favor, escribir SIEMPRE en caso de dudas.
 - Exigir feedback y apoyo.
- Ayudantías no son obligatorias ni tienen nota asociada.
 - Las/los invito a participar y tratar de ajustarse a la metodología que seguiremos en las ayudantías.

Calendario

- Tutorial instalación R y RStudio: Viernes 1 de abril (cápsula).
- Ayudantía 1: Viernes 1 de abril (cápsula).

Calendario todavía sujeto a confirmación por fechas de evaluaciones.

Plan para las ayudantías

- Primeras ayudantías: lo básico.
 - ¿Qué es R?
 - Instalar el software (R y RStudio).
 - Aprender a usar el software.

Metodología

- 5 cápsulas y 4 clases sincrónicas.
- Todas las ayudantías irán acompañadas de una presentación y una hoja de sintaxis en R.
- No desgastarse tomando apuntes, toda la información estará en las presentaciones.

Plan para esta sesión

- Manipulación de objetos en R:
 - Vectores.
 - Matrices.
 - Data frames.
 - Obtener información sobre variables en un data frame.

Usando RStudio

Observaciones

- El símbolo > en la consola indica que R no está corriendo ningún análisis actualmente y que podemos escribir e ingresar código.
- En principio, R lee líneas de código separadas por puntos aparte como funciones diferentes.
- Podemos correr funciones seleccionando el pedazo de texto (código) que nos interesa y apretando Control + Enter (para Windows) y Comando + Enter (MacOS).
- R permite agregar texto a nuestra hoja de sintaxis sin interpretarlo como código, siempre que esté escrito después de #.

Observaciones

```
55+45 #"55+45" es código de R, pero esto no

## [1] 100

#Esta función es útil para comentar nuestro código

#Ayuda a quien lo lea a entenderlo mejor

#(muchas veces nosotros mismos)
```

- Recordemos que R es un lenguaje de programación orientada a objetos.
- Un objeto en R es cualquier cosa a la que podamos asignar información numérica o alfabética.
- Para asignar información a un objeto, usaremos un símbolo de flecha hacia la izquierda: <-.

```
objeto1 <- 1
objeto2 <- 1 + 1
objeto3 <- 2-1
```

- Estas son funciones para crear objetos, pero por sí mismos no nos "muestran" el objeto creado.
- Para "llamar" al objeto creado debemos escribir el nombre del objeto respectivo en la consola.

objeto1

[1] 1

El objeto que aquí llamamos objeto1 contiene el valor numérico 1.

objeto2

[1] 2

• objeto2 contiene la suma de 1+1, por lo tanto al "llamarlo" nos entrega el valor numérico 2.

objeto3

[1] 1

- objeto3 contiene la resta de 2 1, por lo que nos reporta un valor número 1.
- Así, si bien objeto1 y objeto3 nos entregan la misma información (el valor 1), se generan a partir de funciones diferentes.

- Noten como cada objeto fue generado por código escrito en la sintaxis, que R reporta en la consola y se almacena en el environment.
- Los objetos pueden contener información no sólo numérica sino alfabética.
- Para almacenar texto en un objeto, debemos usar comillas: .

```
objeto4 <- "texto"
objeto4
## [1] "texto"
objeto5 <- "abcd"
objeto5
## [1] "abcd"
```

Tipos de objetos en R

Ahora bien, en R hay muchos tipos de objetos, y por ahora nos interesan principalmente 2: los vectores y las bases de datos (data frames), aunque mencionaremos otros.

- Un vector es un tipo de objeto unidimensional que contiene información alfabética o numérica.
- Cuando hablamos de vectores, hablamos de objetos que ya no contienen sólo un valor sino varios valores.

```
vector1 <- c(1, 2, 3, 4, 5)

vector1
## [1] 1 2 3 4 5

vector2 <- c("a", "b", "c", "d", "e")

vector2</pre>
```

```
## [1] "a" "b" "c" "d" "e"
```

Como vemos, vector1 contiene 5 valores numéricos, mientras que vector2 contiene 5 valores alfabéticos.

- El comando c(), llamado concatenate ("concatenar"), será fundamental para poder asignar múltiples valores (esto es, más de un ítem de información) a un mismo objeto.
- Al ir creando objetos de este tipo, R nos permite avanzar de a poco hacia operaciones más complejas.
- Por ejemplo, creemos otro vector llamado vector3 y sumémoslo a vector1.

```
vector3 <- c(6, 7, 8, 9, 10)
vector3
## [1] 6 7 8 9 10
vector1 + vector3</pre>
```

[1] 7 9 11 13 15

- Al sumar vector1 + vector3, obtenemos una nueva información en la consola: los valores 7 9 11 13 15.
- De hecho, podríamos repetir esta operación pero almacenarla en un nuevo vector: vector4.

```
vector1 + vector3

## [1] 7 9 11 13 15

vector4 <- vector1 + vector3

vector4

## [1] 7 9 11 13 15</pre>
```

Sin embargo, no podríamos hacer algo similar con vector2, ya que éste contiene valores alfabéticos y no numéricos.

```
Si ingresan el código
```

```
vector1 + vector2
```

R entregará el siguiente mensaje:

```
Error in vector1 + vector2 : nor
```

- La razón por la que esto ocurre es que vector1 y vector2 pertenecen a "clases" diferentes.
- Con el comando class() podemos ver a qué clase corresponde cada uno.

```
class(vector1)
## [1] "numeric"
class(vector2)
```

```
## [1] "character"
```

- R indica que vector1 es de clase numérica, mientras que vector2 es un carácter. También hay una tercera clase de vector, "factor", que veremos más adelante y es muy útil.
 - Dato importante: si ingresamos números a un vector, pero los números van con comillas, R los entenderá como carácter, no como un valor numérico.

```
vector5 <- c("1", "2", "3", "4", "5")</pre>
vector5
## [1] "1" "2" "3" "4" "5"
class(vector5)
## [1] "character"
str(vector5)
## chr [1:5] "1" "2" "3" "4" "5"
```

■ La función str (structure) también reporta la clase del objeto, además de un resumen de su información.

```
str(vector5)
```

```
## chr [1:5] "1" "2" "3" "4" "5"
```

- En la práctica la gran mayoría de los análisis estadísticos que realizaremos usan vectores numéricos y factores.
- Las funciones de manipulación de texto y caracteres pueden ser muy útiles cuando tenemos que limpiar y depurar bases de datos.

Ejercicio

- Cree un vector que contenga los valores 5, 8, 3, 2 y 10, en ese orden. Llame al vector ejercicio.
- Realice las siguientes operaciones con el vector:
 - Sume 9 a ejercicio.
 - Multiplique ejercicio por 2.
 - Multiplique ejercicio por 5/7.
 - Eleve ejercicio al cuadrado.

Ejercicio

```
ejercicio <- c(5, 8, 3, 2, 10)
ejercicio+9
## [1] 14 17 12 11 19
ejercicio*2
## [1] 10 16 6 4 20
5/7 * ejercicio
## [1] 3.571429 5.714286 2.142857 1.428571 7.142857
ejercicio*ejercicio #o también:
## [1] 25 64 9 4 100
ejercicio<sup>2</sup>
## [1] 25 64 9 4 100
```

[5,]

Tipos de objetos en R: matrices

5

 Una matriz es un tipo de objeto bidimensional que, al igual que un vector, puede tomar valores alfabéticos o numéricos.

```
matriz1

## [,1] [,2] [,3] [,4] [,5]

## [1,] 1 6 11 16 21

## [2,] 2 7 12 17 22

## [3,] 3 8 13 18 23

## [4,] 4 9 14 19 24
```

matriz1 <- matrix(1:25,nrow=5,ncol=5)</pre>

■ El comando le dice a R que cree una matriz cuyos valores vayan del 1 al 25, con 5 filas y 5 columnas.

25

10 15 20

Tipos de objetos en R: matrices

Podemos realizar todas las operaciones del álgebra de matrices:

matriz1+matriz1

```
##
      [,1] [,2] [,3] [,4] [,5]
##
  [1,]
           12 22
                   32
                       42
  [2,]
        4 14 24 34 44
##
## [3,] 6 16 26
                   36 46
## [4,]
        8
           18
               28
                   38 48
## [5,]
       10
           20
               30
                   40
                       50
```

Tipos de objetos en R: matrices

- Nosotros no usaremos mucho las matrices propiamente tales, aunque a veces se pueden usar de forma auxiliar para asistir a otras funciones.
- Sí nos interesa poner atención a la notación de R: cuando vemos números separados por comas entre corchetes [,] estamos hablando de filas y columnas (en ese orden).
- Así, por ejemplo, podemos ver información sólo para filas y columnas de nuestro interés:

Tipos de objetos en R: matrices

■ Cuarta fila y quinta columna de la matriz 1:

```
matriz1[4,5]
## [1] 24
matriz1
        [,1] [,2] [,3] [,4] [,5]
##
  [1,]
                   11
                        16
                             21
##
               6
##
  [2,]
               7 12 17 22
   [3,]
                   13
                        18 23
##
## [4,]
                   14
                        19 24
## [5,]
          5
              10
                   15
                        20
                             25
```

Tipos de objetos en R: bases de datos (data frames)

- Las bases de datos consisten en conjuntos de vectores portadores de valores numéricos o alfabéticos.
- Veamos una muestra de 373 casos elegidos al azar de la III Encuesta Nacional de Participación y Consumo Cultural (2009).

Tipos de objetos en R: bases de datos (data frames)

- La base de datos contiene las siguientes variables:
 - folio (identificador).
 - SEL_Sexo (quizá versiones más actualizadas preguntan por género).
 - SEL_Edad (edad como valor numérico).
 - SEL_NEduc (nivel educativo: grado más alto alcanzado).
 - libros_dummy: m6_64: Con excepción de textos escolares y considerando libros usados o nuevos, ¿ha leído usted algún libro en los últimos 12 meses? (variable dicotómica)
 - libros_numero: m6_66: En los últimos 12 meses, ¿cuántos libros ha leído? (variable numérica)
 - libros_frecuencia: m6_67: Sin considerar textos escolares, ¿con qué frecuencia acostumbra leer libros? (variable categórica con 4 categorías)

- Vamos a seleccionar el directorio donde trabajar:
 - ¿Cómo encontrar rápido el directorio?

getwd()

- ## [1] "C:/GitHub/uah_ayudantia_estadistica_2022/ayudantias"
 - Fijar directorio:

setwd("C:/GitHub/uah ayudantia estadistica 2022/ayudantias")

load("cc1.Rdata")

■ Decirle a R dónde buscar el dataframe en mi computador.

Comandos que servirán para examinar bases de datos: head(), tail(), str(), dim().

```
head(cc1a)
       folio SEL_Sexo SEL_Edad SEL_NEduc libros_dummy libros_numero
## 2335 8577
               Hombre
                           27 Secundaria
## 1853 4924
              Hombre 47 Secundaria
              Mujer 44 Secundaria
## 3311 8839
                                                 Sí
                      34 Secundaria
## 1770 8709
              Muier
                                                 Nο
## 3521 2962
              Hombre
                      24
                               Superior
                                                 Sí
## 5686 2362
                               Primaria
                                                 Sí
              Mujer
                    libros frecuencia
##
## 2335
             Menos de una vez al año
## 1853
              Menos de una vez al año
## 3311 1 día por semana - 1 día al mes
## 1770
               Menos de una vez al año
## 3521 1 día por semana - 1 día al mes
## 5686
              Menos de una vez al mes
```

```
tail(cc1a)
       folio SEL_Sexo SEL_Edad SEL_NEduc libros_dummy libros_numero
## 7631 4310
                           37 Secundaria
               Hombre
## 4977
        7062
              Mujer
                              Primaria
                                                  Nο
## 1285
        7734
              Mujer
                                                  Sí
                       61
                                Superior
                       55 Secundaria
## 6407
        2756 Hombre
                                                  No
## 5262
        2994
              Muier
                                Primaria
                                                  Sí
## 4333 8578
               Hombre
                                                  No
                                Superior
##
                    libros_frecuencia
## 7631 1 día por semana - 1 día al mes
## 4977
               Menos de una vez al año
## 1285
         Todos o casi todos los días
## 6407
               Menos de una vez al año
## 5262 1 día por semana - 1 día al mes
## 4333
               Menos de una vez al año
```

```
str(cc1a)
## 'data.frame': 373 obs. of 7 variables:
##
   $ folio
                      : int 8577 4924 8839 8709 2962 2362 6247 3396 4163 6779
##
   $ SEL Sexo
                      : chr "Hombre" "Hombre" "Mujer" "Mujer" ...
   $ SEL Edad
                      : int 27 47 44 34 24 70 25 49 49 68 ...
##
##
   $ SEL NEduc : Factor w/ 3 levels "Primaria", "Secundaria", ...: 2 2 2 2
   $ libros dummy : chr "No" "No" "Sí" "No" ...
##
##
   $ libros numero : int 0 0 4 0 5 1 0 2 2 2 ...
   $ libros frecuencia: Factor w/ 4 levels "Todos o casi todos los días",...: 4
##
##
   - attr(*, "na.action") = 'omit' Named int [1:27] 9 25 29 44 74 76 119 132 14
##
    ..- attr(*, "names")= chr [1:27] "7054" "355" "2268" "2993" ...
```

```
dim(cc1a)
## [1] 373 7
```

198 175

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Conteo de frecuencias de sexo y lectura de libros en el último año:

```
table(cc1a$SEL_Sexo)

##
## Hombre Mujer
## 172 201
table(cc1a$libros_dummy)

##
##
## No Si
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Proporciones de cada categoría de sexo y lectura en los últimos 12 meses:

```
## ## Hombre Mujer

## 0.461126 0.538874

prop.table(table(cc1a$libros_dummy))

## No Si

## 0.5308311 0.4691689
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Frecuencias de qué tan seguido leen las personas encuestadas:

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos de descriptivos univariados:
 - Proporciones de qué tan seguido leen las personas encuestadas:

```
## ## Todos o casi todos los días 1 día por semana - 1 día al mes ## 0.1554960 0.2010724 ## Menos de una vez al mes Menos de una vez al año ## 0.1126005 0.5308311
```

- Proporciones de qué tan seguido leen las personas encuestadas:
- Para mejor presentación de las proporciones:

```
## ## Todos o casi todos los días 1 día por semana - 1 día al mes ## 15.54960 20.10724 ## Menos de una vez al mes Menos de una vez al año ## 11.26005 53.08311
```

 Proporciones de qué tan seguido leen las personas encuestadas:

round(100*prop.table(table(cc1a\$libros_frecuencia)),digits=1)

■ Para mejor presentación de las proporciones:

```
##
## Todos o casi todos los días 1 día por semana - 1 día al mes
## 15.5 20.1
## Menos de una vez al mes Menos de una vez al año
## 11.3 53.1
```

- Para acceder a una variable en particular dentro de la base de datos, debemos usar el comando \$.
- Ejemplos:
 - ¿Cuáles son la media y la mediana de libros leídos el último año?

```
mean(cc1a$libros_numero)

## [1] 1.865952

median(cc1a$libros_numero)
```

[1] 0

- Al igual que con las matrices, podemos utilizar los corchetes para señalar filas y columnas de nuestro interés.
- Por ejemplo, veamos qué valor tiene en la fila 100 la pregunta sobre frecuencia de lectura:

```
## [1] Todos o casi todos los días
## 4 Levels: Todos o casi todos los días ... Menos de una vez al año
#o lo mismo escrito de otra forma:
cc1a[100,7]

## [1] Todos o casi todos los días
## 4 Levels: Todos o casi todos los días ... Menos de una vez al año
#porque libros_frecuencia es la séptima variable (columna)
#de nuestro data frame
```

O los valores de las tres variables sobre lectura en las filas 150 y 251:

```
cc1a[150.c("libros dummv", "libros numero", "libros frecuencia")]
       libros dummy libros numero libros frecuencia
                               O Menos de una vez al año
## 8049
cc1a[251,c("libros dummv", "libros numero", "libros frecuencia")]
      libros dummy libros numero libros frecuencia
##
## 536
                              2 Todos o casi todos los días
#o lo mismo escrito de otra forma:
cc1a[251.5:7]
      libros_dummy libros_numero libros_frecuencia
                              2 Todos o casi todos los días
## 536
#porque las variables son la número 5, 6 v 7
#de nuestro data frame
```

- Veamos ahora algunos descriptivos bivariados (variable numérica según variable categórica):
 - Cómo se distribuyen las medias de una variable numérica según las diferentes categorías de nivel educativo y sexo.

```
tapply(cc1a$libros numero, cc1a$SEL NEduc, mean)
##
    Primaria Secundaria Superior
    1.021505 1.804878 3.080000
##
#media de libros leídos por año según nivel educativo
tapply(cc1a$libros numero, cc1a$SEL Sexo, mean)
##
    Hombre
              Mujer
## 1.110465 2.512438
#media de libros leídos por año seqún sexo
```

Todos o casi todos los días

Menos de una vez al año

Menos de una vez al mes

1 día por semana - 1 día al mes

Tipos de objetos en R: bases de datos (data frames)

 Veamos ahora algunos descriptivos bivariados (asociación entre variables categóricas, que se registra en una tabla de contingencia):

```
table(cc1a$libros_frecuencia,cc1a$SEL_NEduc)
##
##
                                     Primaria Secundaria Superior
## Todos o casi todos los días
                                            14
                                                       26
                                                                18
##
    1 día por semana - 1 día al mes
                                            13
                                                                11
## Menos de una vez al mes
                                                                17
    Menos de una vez al año
                                            62
                                                      107
                                                                29
#frecuencia de lectura según nivel educativo
#quardemos esto como objeto para mayor simplicidad:
lectura_NEduc <- table(cc1a$libros_frecuencia,cc1a$SEL_NEduc)</pre>
#lo mismo de otra manera:
xtabs(~libros_frecuencia+SEL_NEduc, data=cc1a)
##
                                    SEL NEduc
## libros_frecuencia
                                     Primaria Secundaria Superior
```

14

1.3

62

26

21

107

18

11

17

29

- Veamos ahora algunos descriptivos bivariados (asociación entre variables categóricas):
 - Se entiende mejor con proporciones:

```
round(100*prop.table(lectura_NEduc),2)
```

```
##
##
                                    Primaria Secundaria Superior
    Todos o casi todos los días
                                        3.75
                                                           4.83
##
                                                  6.97
     1 día por semana - 1 día al mes
                                        3.49
                                                  13.67
                                                           2.95
##
    Menos de una vez al mes
                                        1.07
                                                  5.63 4.56
##
                                       16.62
                                                 28.69
                                                           7.77
##
    Menos de una vez al año
```

- Veamos ahora algunos descriptivos bivariados (asociación entre variables categóricas):
 - Se entiende mejor con proporciones (*porcentaje de columna*):

```
round(100*prop.table(lectura_NEduc, margin=2),2)
##
                                  Primaria Secundaria Superior
##
##
    Todos o casi todos los días
                                     15.05
                                               12.68
                                                       24.00
    1 día por semana - 1 día al mes 13.98
                                               24.88
                                                       14.67
##
##
    Menos de una vez al mes
                                    4.30
                                              10.24
                                                       22,67
##
    Menos de una vez al año
                                 66.67
                                               52.20
                                                       38.67
```

#el porcentaje de columna se especifica con margin=2

```
##
##
                                      Primaria Secundaria Superior
     Todos o casi todos los días
                                         15.05
                                                     12.68
                                                              24 00
##
     1 día por semana - 1 día al mes
                                         13.98
                                                     24.88
                                                              14.67
##
    Menos de una vez al mes
                                         4.30
                                                     10.24
                                                              22.67
##
     Menos de una vez al año
                                         66.67
                                                     52.20
                                                              38 67
```

- ¿Cómo interpretar el porcentaje de columna? De arriba hacia abajo, todas las columnas suman 100 % (no así las filas de izquierda a derecha).
- Nos indican cómo varía la frecuencia de lectura según nivel educativo.
- Así, entre quienes están/alcanzaron la primaria, alrededor del 67 % declara que lee menos de un libro al año, mientras que el 15 % lee todos o casi todos los días.
- Entre quienes están/alcanzaron la educación superior, alrededor del 39 % no lee casi nunca, mientras que el 24 % lee todos o casi todos los días.

Ahora con *porcentaje de fila*:

```
round(100*prop.table(lectura_NEduc, margin=1),2)
##
##
                                     Primaria Secundaria Superior
                                        24.14
                                                   44.83
                                                            31.03
##
    Todos o casi todos los días
##
    1 día por semana - 1 día al mes
                                        17.33
                                                   68.00
                                                            14.67
##
    Menos de una vez al mes
                                        9.52
                                                   50.00
                                                            40.48
   Menos de una vez al año
                                        31.31
                                                   54.04
                                                           14.65
#el porcentaje de columna se especifica con margin=1
```

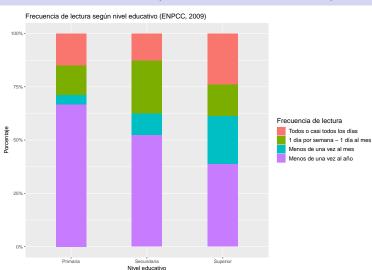
- ¿Cómo interpretar el porcentaje de fila? De izquierda a derecha, todas las filas suman 100% (no así las columnas de arriba hacia abajo).
- Nos indica cómo varía el nivel educativo en cada tramo/grupo/categoría de frecuencia de lectura.
- Así, entre quienes leen todos/casi todos los días, alrededor del 24 % alcanzó la educación primaria, mientras que el 31 % alcanzó la educación superior.
- Entre quienes leen menos de un libro al año, el 31 % alcanzó la primaria, mientras que el 15 % alcanzó la educación superior.

Propuesta de ejercicio

Propuesta de ejercicio (totalmente voluntario)

- Utilizando la base de datos cc1a (archivo cc1.Rdata) que analizamos esta clase, y el código visto en clases y en ayudantía, haga un análisis de la lectura en Chile según nuestros datos.
- Puede incluir tablas de descriptivos univariados o bivariados, además de gráficos.

Propuesta de ejercicio (totalmente voluntario)



Propuesta de ejercicio (totalmente voluntario)

- Más allá del código, ¿qué información o aprendizaje nos dejan los datos? ¿Hay alguna hipótesis que le parezca pertinente investigar? Sea creativo/a, estamos aprendiendo y equivocarnos da lo mismo.
- Este ejercicio se trata en parte de usar el código, pero también de formular una narración que resuma lo que aprendimos de los datos.
- Deberíamos aspirar a analizar datos para poder evaluar argumentos y teorías.

Bibliografía

Referencias sugeridas

En castellano:

- Hernández, F., & Usuga, O. (2021a). Introducción. En Manual de R. https://fhernanb.github.io/Manual-de-R/ (disponible gratuitamente online).
- Hernández, F., & Usuga, O. (2021b). Tipos de objetos. En Manual de R. https://fhernanb.github.io/Manual-de-R/objetos.html (disponible gratuitamente online).

Referencias sugeridas

En inglés:

■ Paradis, E. (2013). *R for Beginners*. 1–52.

Referencias complementarias (consulta)

- Beaujean, A. A. (2014). Introduction to R. En Latent Variable Modeling Using R (pp. 1–33). Routledge.
- Gorgas, J., & Cardiel, N. (s.f.). Tema 1: Introducción al paquete de software R. https://www.ucm.es/data/cont/docs/339-2016-09-29-Introduccion%20a%20R_v1617.pdf (infografías).
- Zuur, A. F., Ieno, E. N., & Meesters, E. H. W. G. (2009). Ch.
 2: Getting Data into R. En A Beginner's Guide to R
 (pp. 29–56). Springer.

Sobre la lectura

- La lectura es de carácter voluntario y no se evaluará.
- Se recomienda leer 1 de las lecturas sugeridas y revisar las complementarias como material de consulta.